


Monte Carlo vs SARSA vs Q-Learning sur Taxi-v4

Implémentation tabulaire, comparaison expérimentale et influence
des hyperparamètres α , γ , ϵ .

Groupe : **Lorenzo Faloci** • *[noms des collègues]*

github.com/lorenino/RL_TP_Taxi – code, figures, rapport



grille 5x5 • 4 arrêts • murs

Taxi-v4 : aller chercher, déposer, sans se tromper

États	500 = 25 cases taxi × 5 positions passager (4 arrêts + à bord) × 4 destinations
Actions	6 : sud · nord · est · ouest · <i>pickup</i> · <i>dropoff</i>
Récompenses	-1 par pas · +20 dropoff réussi · -10 pickup/dropoff illégal
Fin d'épisode	dropoff réussi (terminated) ou 200 pas (truncated)
Repères	politique aléatoire ≈ -768 · optimal ≈ +7,9 (trajet moyen ~13 pas)

POURQUOI CET ENVIRONNEMENT

- Consigne : un environnement Gymnasium **non traité en cours** — FrozenLake, CliffWalking et Blackjack sont exclus.
- Discret et tabulaire : les trois algos s'appliquent **sans approximation** (Q-table 500×6).
- Assez riche pour les différencier : récompenses piégeuses (-10), horizon long, timeout.

Trois algorithmes, une seule différence : la cible de mise à jour

Squelette **identique** pour les trois : Q-table 500×6 initialisée à 0, politique de comportement ϵ -greedy, mise à jour $Q(s, a) \leftarrow Q(s, a) + \alpha \cdot (\text{cible} - Q(s, a))$. Seule la **cible** change :

Monte Carlo

$$G = r_1 + \gamma r_2 + \gamma^2 r_3 + \dots$$

RETOUR COMPLET • FIN D'ÉPISODE

Attends la fin de l'épisode, utilise le retour **réellement observé**. Sans biais de bootstrap, mais **forte variance** : tout le hasard de l'épisode entre dans la cible.

SARSA

$$r + \gamma \cdot Q(s', a')$$

TD • ON-POLICY

Met à jour à chaque pas ; **a' est l'action réellement jouée** ensuite. Apprend la valeur de la politique ϵ -greedy **elle-même**, exploration comprise.

Q-Learning

$$r + \gamma \cdot \max_a Q(s', a')$$

TD • OFF-POLICY

Met à jour à chaque pas avec la **meilleure** action suivante possible. Apprend la politique **optimale**, quelle que soit la façon d'explorer.

Protocole expérimental

ENTRAÎNEMENT

12 000 épisodes par run.

Comparaison : moyenne sur **5 seeds** ; grilles d'hyperparamètres : **3 seeds**.

Config de référence : $\alpha = 0,1$ · $\gamma = 0,99$ · ε : decay linéaire $1,0 \rightarrow 0,05$.

ANALYSE DES HYPERPARAMÈTRES

Un facteur varie, les autres restent à la référence :

$\alpha \in \{0,05 \cdot 0,1 \cdot 0,3 \cdot 0,7\}$

$\gamma \in \{0,90 \cdot 0,99 \cdot 1,0\}$

$\varepsilon \in \{0,01 \cdot 0,1 \cdot 0,3 \cdot \text{decay}\}$

Deux métriques à ne pas confondre

Courbes d'apprentissage

Reward de la politique

de comportement

(ε -greedy, exploration comprise) pendant l'entraînement — fenêtre glissante de 200 épisodes.

Évaluation greedy

Reward moyen de la politique

finale extraite


($\arg\max Q, \varepsilon = 0$) sur 500 épisodes. C'est

elle

qui juge ce qui a été appris.

SARSA et Q-Learning atteignent l'optimal, Monte Carlo reste en retrait

Taxi-v4 — Monte Carlo vs SARSA vs Q-Learning (alpha=0.1, gamma=0.99, eps=decay)




Politique greedy finale	Reward moyen	Succès	Pas/épisode
Aléatoire (baseline)	-767,7	~0 %	200
■ Monte Carlo	+3,8	98,3 %	16,8
■ SARSA	+7,9	100 %	13,1
■ Q-Learning	+7,9	100 %	13,1

Lecture

Q-Learning apprend le plus vite (cible max). Les deux méthodes TD finissent **indistinguables** : Taxi est **déterministe**, la prudence de SARSA ne change rien (contrairement à CliffWalking). MC converge, mais la **variance du retour complet** le laisse à +3,8.

α classe les algos par la variance de leur cible

Taxi-v4 — influence de alpha (autres facteurs fixes : base)




Greedy finale	$\alpha = 0,05$	$\alpha = 0,1$	$\alpha = 0,3$	$\alpha = 0,7$
■ Monte Carlo	+0,6	+1,7	-291,8	-619,5
■ SARSA	+7,3	+7,8	+7,9	-255,8
■ Q-Learning	+7,9	+7,9	+7,9	+7,9

Lecture

MC diverge dès $\alpha = 0,3$: grand pas $\times$ cible à forte variance, chaque épisode malchanceux écrase la Q-table. SARSA casse à 0,7 — sa courbe de comportement paraît converger, mais la greedy est mauvaise (67 % de succès). **Q-Learning est insensible** sur toute la plage.

γ agit en sens opposés sur Monte Carlo et SARSA

Taxi-v4 — influence de gamma (autres facteurs fixes : base)




Greedy finale	$\gamma = 0,90$	$\gamma = 0,99$	$\gamma = 1,0$
■ Monte Carlo	+6,1	+1,7	-58,5
■ SARSA	-9,0	+7,8	+7,9
■ Q-Learning	+7,9	+7,9	+7,9

Lecture

MC préfère $\gamma = 0,9$: l'actualisation réduit la variance du retour ; à $\gamma = 1$, les épisodes tronqués à 200 pas noient l'assignation de crédit. **SARSA souffre à $\gamma = 0,9$** : horizon effectif ~ 10 pas < trajet moyen (13) — loin du but, le signal de valeur devient trop faible.

ϵ : le piège de lecture, et l'on-policy qui paie l'exploration

Taxi-v4 — influence de epsilon (autres facteurs fixes : base)



Greedy finale	$\epsilon = 0,01$	$\epsilon = 0,1$	$\epsilon = 0,3$	$\epsilon = \text{decay}$
■ Monte Carlo	-230,8	-140,2	-38,7	+1,7
■ SARSA	+7,9	+7,9	-5,0	+7,8
■ Q-Learning	+7,9	+7,9	+7,9	+7,9

Lecture

Sur les courbes, $\epsilon = 0,01$ paraît excellent... mais la greedy de MC finit à **1,3 % de succès** : la courbe de comportement ne suffit jamais. SARSA/Q-Learning survivent au petit ϵ (Q init à 0 = **optimiste** → exploration implicite). À $\epsilon = 0,3$, **SARSA paie l'exploration dans ses Q** (-5,0), Q-Learning non : c'est l'écart on-policy / off-policy, mesuré.

Ce qu'il faut retenir

ROBUSTESSE AUX HYPERPARAMÈTRES — CONFIGS À L'OPTIMAL SUR 11 TESTÉES

Q-Learning 11/11 >> **SARSA 8/11** >> **Monte Carlo 0/11**

1 À config bien réglée, **SARSA et Q-Learning atteignent l'optimal** (+7,9, 100 % de succès) ; MC s'en approche (+3,8) sans y arriver en 12 000 épisodes.

2 La fragilité de MC a **une seule cause racine : la variance du retour complet** (pas de bootstrap). Elle explique tout : divergence à grand α , crédit noyé à $\gamma = 1$, dépendance vitale au decay d' ϵ .

3 **On-policy vs off-policy se mesure** : SARSA intègre le coût de l'exploration dans ses Q ($\epsilon = 0,3 \rightarrow -5,0$), Q-Learning apprend la greedy quoi qu'il explore.

4 Taxi est **déterministe** : les politiques finales SARSA/Q-Learning coïncident. La prudence de SARSA ne paierait que sur un environnement risqué (cf. CliffWalking).

Merci — questions ?

Code, figures, rapport détaillé et [resultats.json](#)

github.com/lorenino/RL_TP_Taxi

Pourquoi MC à pas constant plutôt que la moyenne 1/N ?

Pour analyser α sur les **trois** algos, et parce qu'en contrôle la politique change sans cesse : cible non-stationnaire $\rightarrow$ un pas constant oublie les retours obsolètes (S&B §6.1).

Que faites-vous du timeout à 200 pas ?

terminated = vraie fin du MDP $\rightarrow$ cible = r seul. **truncated** = artefact du TimeLimit $\rightarrow$ on **bootstrapte normalement** sur s' . Les confondre biaise Q près de la limite.

SARSA = Q-Learning ici, mais pas sur CliffWalking ?

CliffWalking pénalise le chemin risqué **pendant l'exploration** : SARSA (on-policy) choisit le chemin sûr, Q-Learning le bord de falaise. Taxi n'a pas de risque de ce type : les deux convergent vers la même politique.