


# Monte Carlo vs SARSA vs Q-Learning sur Taxi-v4

Implémentation tabulaire, comparaison expérimentale et influence  
des hyperparamètres  $\alpha$ ,  $\gamma$ ,  $\epsilon$ .

Groupe : **Lorenzo Faloci** · **Talha Tecim** · **Nicolas Guillard**

[github.com/lorenino/RL\\_TP\\_Taxi](https://github.com/lorenino/RL_TP_Taxi) – code, figures, rapport



grille 5x5 • 4 arrêts • murs

# Taxi-v4 : aller chercher, déposer, sans se tromper

|               |                                                                                        |
|---------------|----------------------------------------------------------------------------------------|
| États         | <b>500</b> = 25 cases taxi × 5 positions passager (4 arrêts + à bord) × 4 destinations |
| Actions       | <b>6</b> : sud · nord · est · ouest · <i>pickup</i> · <i>dropoff</i>                   |
| Récompenses   | <b>-1</b> par pas · <b>+20</b> dropoff réussi · <b>-10</b> pickup/dropoff illégal      |
| Fin d'épisode | dropoff réussi ( <b>terminated</b> ) ou 200 pas ( <b>truncated</b> )                   |
| Repères       | politique aléatoire ≈ <b>-768</b> · optimal ≈ <b>+7,9</b> (trajet moyen ~13 pas)       |

## POURQUOI CET ENVIRONNEMENT

- Consigne : un environnement Gymnasium **non traité en cours** — FrozenLake, CliffWalking et Blackjack sont exclus.
- Discret et tabulaire : les trois algos s'appliquent **sans approximation** (Q-table  $500 \times 6$ ).
- Assez riche pour les différencier : récompenses piégeuses (-10), horizon long, timeout.

# Trois algorithmes, une seule différence : la cible de mise à jour

Squelette **identique** pour les trois : Q-table  $500 \times 6$  initialisée à 0, politique de comportement  $\epsilon$ -greedy, mise à jour  $Q(s, a) \leftarrow Q(s, a) + \alpha \cdot (\text{cible} - Q(s, a))$ . Seule la **cible** change :

## Monte Carlo

$$G = r_1 + \gamma r_2 + \gamma^2 r_3 + \dots$$

### RETOUR COMPLET • FIN D'ÉPISODE

Attends la fin de l'épisode, utilise le retour **réellement observé**. Sans biais de bootstrap, mais **forte variance** : tout le hasard de l'épisode entre dans la cible.

## SARSA

$$r + \gamma \cdot Q(s', a')$$

### TD • ON-POLICY

Met à jour à chaque pas ; **a' est l'action réellement jouée** ensuite. Apprend la valeur de la politique  $\epsilon$ -greedy **elle-même**, exploration comprise.

## Q-Learning

$$r + \gamma \cdot \max_a Q(s', a')$$

### TD • OFF-POLICY

Met à jour à chaque pas avec la **meilleure** action suivante possible. Apprend la politique **optimale**, quelle que soit la façon d'explorer.

# Protocole expérimental

## ENTRAÎNEMENT

**12 000 épisodes** par run.

Comparaison : moyenne sur **5 seeds** ; grilles d'hyperparamètres : **3 seeds**.

Config de référence :  $\alpha = 0,1$  ·  $\gamma = 0,99$  ·  $\varepsilon$  : decay linéaire  $1,0 \rightarrow 0,05$ .

## ANALYSE DES HYPERPARAMÈTRES

Un facteur varie, les autres restent à la référence :

$\alpha \in \{0,05 \cdot 0,1 \cdot 0,3 \cdot 0,7\}$

$\gamma \in \{0,90 \cdot 0,99 \cdot 1,0\}$

$\varepsilon \in \{0,01 \cdot 0,1 \cdot 0,3 \cdot \text{decay}\}$

## Deux métriques à ne pas confondre

### Courbes d'apprentissage

Reward de la politique

### de comportement

( $\varepsilon$ -greedy, exploration comprise) pendant l'entraînement — fenêtre glissante de 200 épisodes.

### Évaluation greedy

Reward moyen de la politique

### finale extraite


( $\arg\max Q, \varepsilon = 0$ ) sur 500 épisodes. C'est

### elle

qui juge ce qui a été appris.

# SARSA et Q-Learning atteignent l'optimal, Monte Carlo reste en retrait

Taxi-v4 — Monte Carlo vs SARSA vs Q-Learning (alpha=0.1, gamma=0.99, eps=decay)




| Politique greedy finale | Reward moyen | Succès | Pas/épisode |
|-------------------------|--------------|--------|-------------|
| Aléatoire (baseline)    | -767,7       | ~0 %   | 200         |
| ■ Monte Carlo           | +3,8         | 98,3 % | 16,8        |
| ■ SARSA                 | +7,9         | 100 %  | 13,1        |
| ■ Q-Learning            | +7,9         | 100 %  | 13,1        |

## Lecture

Q-Learning apprend le plus vite (cible max). Les deux méthodes TD finissent **indistinguables** : Taxi est **déterministe**, la prudence de SARSA ne change rien (contrairement à CliffWalking). MC converge, mais la **variance du retour complet** le laisse à +3,8.

# $\alpha$ classe les algos par la variance de leur cible

Taxi-v4 — influence de alpha (autres facteurs fixes : base)




| Greedy finale | $\alpha = 0,05$ | $\alpha = 0,1$ | $\alpha = 0,3$ | $\alpha = 0,7$ |
|---------------|-----------------|----------------|----------------|----------------|
| ■ Monte Carlo | +0,6            | +1,7           | -291,8         | -619,5         |
| ■ SARSA       | +7,3            | +7,8           | +7,9           | -255,8         |
| ■ Q-Learning  | +7,9            | +7,9           | +7,9           | +7,9           |

## Lecture

**MC diverge dès  $\alpha = 0,3$**  : grand pas  $\times$  cible à forte variance, chaque épisode malchanceux écrase la Q-table. SARSA casse à 0,7 — sa courbe de comportement paraît converger, mais la greedy est mauvaise (67 % de succès). **Q-Learning est insensible** sur toute la plage.

# $\gamma$ agit en sens opposés sur Monte Carlo et SARSA

Taxi-v4 — influence de gamma (autres facteurs fixes : base)




| Greedy finale | $\gamma = 0,90$ | $\gamma = 0,99$ | $\gamma = 1,0$ |
|---------------|-----------------|-----------------|----------------|
| ■ Monte Carlo | +6,1            | +1,7            | -58,5          |
| ■ SARSA       | -9,0            | +7,8            | +7,9           |
| ■ Q-Learning  | +7,9            | +7,9            | +7,9           |

## Lecture

**MC préfère  $\gamma = 0,9$**  : l'actualisation réduit la variance du retour ; à  $\gamma = 1$ , les épisodes tronqués à 200 pas noient l'assignation de crédit. **SARSA souffre à  $\gamma = 0,9$**  : horizon effectif  $\sim 10$  pas < trajet moyen (13) — loin du but, le signal de valeur devient trop faible.

# $\epsilon$ : le piège de lecture, et l'on-policy qui paie l'exploration

Taxi-v4 — influence de epsilon (autres facteurs fixes : base)



| Greedy finale | $\epsilon = 0,01$ | $\epsilon = 0,1$ | $\epsilon = 0,3$ | $\epsilon = \text{decay}$ |
|---------------|-------------------|------------------|------------------|---------------------------|
| ■ Monte Carlo | -230,8            | -140,2           | -38,7            | +1,7                      |
| ■ SARSA       | +7,9              | +7,9             | -5,0             | +7,8                      |
| ■ Q-Learning  | +7,9              | +7,9             | +7,9             | +7,9                      |

## Lecture

Sur les courbes,  $\epsilon = 0,01$  paraît excellent... mais la greedy de MC finit à **1,3 % de succès** : la courbe de comportement ne suffit jamais. SARSA/Q-Learning survivent au petit  $\epsilon$  (Q init à 0 = **optimiste** → exploration implicite). À  $\epsilon = 0,3$ , **SARSA paie l'exploration dans ses Q** (-5,0), Q-Learning non : c'est l'écart on-policy / off-policy, mesuré.

# Ce qu'il faut retenir

ROBUSTESSE AUX HYPERPARAMÈTRES — CONFIGS À L'OPTIMAL SUR 11 TESTÉES

**Q-Learning 11/11** >> **SARSA 8/11** >> **Monte Carlo 0/11**

**1** À config bien réglée, **SARSA et Q-Learning atteignent l'optimal** (+7,9, 100 % de succès) ; MC s'en approche (+3,8) sans y arriver en 12 000 épisodes.

**2** La fragilité de MC a **une seule cause racine : la variance du retour complet** (pas de bootstrap). Elle explique tout : divergence à grand  $\alpha$ , crédit noyé à  $\gamma = 1$ , dépendance vitale au decay d' $\epsilon$ .

**3** **On-policy vs off-policy se mesure** : SARSA intègre le coût de l'exploration dans ses Q ( $\epsilon = 0,3 \rightarrow -5,0$ ), Q-Learning apprend la greedy quoi qu'il explore.

**4** Taxi est **déterministe** : les politiques finales SARSA/Q-Learning coïncident. La prudence de SARSA ne paierait que sur un environnement risqué (cf. CliffWalking).

# Merci — questions ?

Code, figures, rapport détaillé et [resultats.json](#)

[github.com/lorenino/RL\\_TP\\_Taxi](https://github.com/lorenino/RL_TP_Taxi)

## Pourquoi MC à pas constant plutôt que la moyenne $1/N$ ?

Pour analyser  $\alpha$  sur les **trois** algos, et parce qu'en contrôle la politique change sans cesse : cible non-stationnaire  $\rightarrow$  un pas constant oublie les retours obsolètes (S&B §6.1).

## Que faites-vous du timeout à 200 pas ?

**terminated** = vraie fin du MDP  $\rightarrow$  cible =  $r$  seul. **truncated** = artefact du TimeLimit  $\rightarrow$  on **bootstrapte normalement** sur  $s'$ . Les confondre biaise  $Q$  près de la limite.

## SARSA = Q-Learning ici, mais pas sur CliffWalking ?

CliffWalking pénalise le chemin risqué **pendant l'exploration** : SARSA (on-policy) choisit le chemin sûr, Q-Learning le bord de falaise. Taxi n'a pas de risque de ce type : les deux convergent vers la même politique.